

## 数据结构

授课教师:

湖南大学 信息科学与工程学院

第9章

不相交集

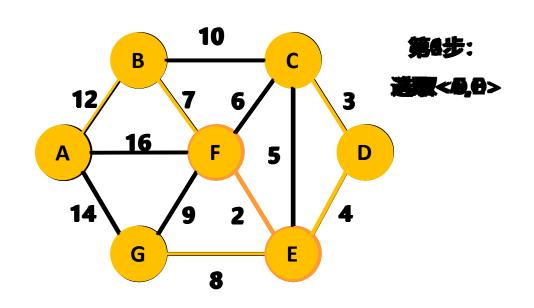
# 提纲

- 9.1 问题引入
- 9.2 等价关系、等价类和不相交集
- 9.3 不相交集的存储实现
- 9.4 不相交集的基本运算实现
- 9.5 不相交集的应用
- 9.6 拓展延伸
- 9.7 应用场景



## 9.1 问题引入: Kruskal算法的高效实现

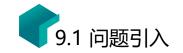
- 求最小生成树的Kruskal算法:
- 按权重递增顺序考虑每条边
- 并把连接不同连通分量的边e = (u, v)加入生成树。
- 这需要动态地维护图的连通性
- 需要支持下列三种操作:
  - (初始化) 初始化一个无向图G = (V, E), 其中 $E = \emptyset$  (空集),即每个顶点分属于不同的连通分量。
  - (加边) 在图中加入一条边(u,v):  $E \leftarrow E \cup \{(u,v)\}$ 。
  - (连通性查询)查询顶点*u*和顶点*v*是否属于同一连通分量,即查询两顶点之间是否有路径相连。





## 9.1 问题引入: Kruskal算法的高效实现

- 直接做法: 利用无向图实现
- 加边操作只需*O*(1)时间;
- 连通性查询可以通过图的遍历实现,在n = |V|个顶点的图中,每次查询最坏需要O(n)。
- 在Kruskal算法中,对每条边均需要进行一次连通性查询,因此m=|E|次查询的总时间复杂度为O(nm)。



## 9.1 问题引入:Kruskal算法的高效实现

- 注意:只需要查询顶点之间是否连通,不关心它们具体通过哪条路径连通
- 此外,只需要支持**加边操作**,而不需要支持**删边操作**。
- 这种情况下,与其完整地维护无向图的结构,不如直接维护连通分量构成的集合
- 每个连通分量用其中顶点的集合表示。

初始时,每个顶点都是独立的连通分量,此时有n个仅包含单一顶点的集合: $\{v_1\},\{v_2\},...,\{v_n\}$ 

每加入一条边(*u*,*v*), 就将*u*所属的集合和*v* 所属的集合合并



对于连通性查询 (*u*,*v*), 只需查询*u*和 *v*是否在同一集合中



1

2

连通性查询问题变成了维护若干不相交的集合,并动态地合并、查找的问题。



## 9.1 问题引入: Kruskal算法的高效实现

• 利用不相交集的数据结构,这些集合操作仅需每操作 $O(\alpha(n))$ 的时间复杂度,其中 $\alpha(\cdot)$ 是一个增长极其缓慢的函数,一般可以认为 $\alpha(n) \le 4$  。该时间复杂度仅略高于O(1),而大大低于图的遍历所需的O(n)。

- 不相交集与数学中等价关系、等价类的概念密切相关
- 元素之间的等价关系自然地定义了若干不相交集的集合
- 因此,不相交集常常用于处理等价性查询的问题
- 例如,两个顶点在同一连通分量中就可以看做一种等价性

## 等价性查询的一般定义:

定义 9-1. (等价关系) 称在集合X上的二元关系~为一个等价关系, 若其满足:

- (自反性) ∀a ∈ X, 有a ~ a;
- (对称性) ∀a,b ∈ X, 若a ~ b, 则b ~ a;
- (传递性) ∀a,b,c ∈ X, 若a ~ b, b ~ c, 则a ~ c。

- 一个最常见的等价关系是定义在整数集Z上的相等关系=。不难验证,该关系满足定义9-1中的三条性质。
- 等价关系将"相等"的概念推广到了一般的集合。

#### 例 9.1. 不同问题中的等价关系:

- ✓ 对于平面上全部三角形构成的集合R<sup>6</sup>, 三角形之间的全等关系≌以及相似关系~均 为等价关系
- ✓ 对于所有生物构成的集合,两种生物是否属于同一科构成一个等价关系。

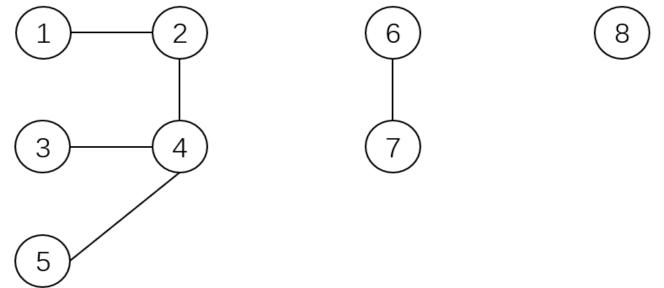
对集合中的任意元素, 称所有与其等价的元素为一个等价类:

定义 9-2. (等价类) 给定集合X和等价关系~,定义某一元素a ∈ X的等价类为{x ∈ X, x ~ a}。

- 定义 9-3. (商集)集合X关于等价关系~的商集记作X/~,定义为:
  - $X/\sim := \{\{x \in X, x \sim a\}, a \in X\}.$

商集是一系列集合,这些集合彼此不相交,并且其并集是全集X。这与不相交集的概念恰好对应。

- 例 9.2. 在下图所示的无向图G = (V, E)中,考虑顶点间的连通关系 $\sim$  (见例9.1)。
- 该连通关系将点集V划分为了三个等价类,分别为{1,2,3,4,5}、{6,7}和{8}。这些等价类彼此不相交,且它们的并集为全集V。本例中,每个等价类是一个无向图中的连通分量。



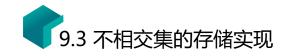
无向图G = (V, E)中连通性等价关系定义的等价类

- 不相交集可以用于等价性的动态查询。
- 等价性的查询在计算机科学中有广泛应用。例如,在编译器的设计中,用于 判断符号地址的等价性。

不相交集维护某集合X关于等价关系~的商集X/~

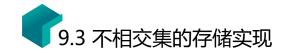
等价关系的增加对应Union操作,即将两个等价类合并

等价性的查询对应Find操作。若要查询两元素x、y的等价性, 需判断是否有Find(x) = Find(y)



## 9.3 不相交集的存储实现

- 不相交集数据结构定义:
- 给定n个元素组成的集合X。不失一般性,令 $X = \{1,2,...,n\}$ 。 不相交集的数据结构动态维护了集合X的一组划分,即若干个不相交的集合  $X_1,...,X_m$ ,满足:
  - $\forall i \neq j, X_i \cap X_j = \emptyset;$
  - $\bigcup_{i=1}^m Xi = X_{\circ}$
- 例:考虑集合X={1, 2, 3, 4, 5, 6, 7, 8}。
- 合法的划分: {{1, 2, 3, 4, 5}, {6, 7}, {8}}或{{1} {2}, {3}, {4}, {5}, {6}, {7}, {8}};
- 以下不是集合X的划分: {{1, 2, 3, 4, 5}, {6, 7}}和{{1, 2, 3}, {3, 4, 5}, {5, 6, 7, 8}}。



## 9.3 不相交集的存储实现

不相交集的数据结构需要动态处理集合的合并和查询操作,其ADT定义如下:

```
代码 9-1 不相交集的抽象数据类型定义
ADT DisjointSet {
数据对象:
    n个元素构成的全集X。
数据关系:
    \{\langle i,j \rangle | i,j \in X\}表示i,j属于同一个集合。
基本操作:
   InitSet(set, n):
      建立n个不相交的集合X_1, ..., X_n,其中每个集合初始只有一个元素: X_i = \{i\}, \forall i = i\}
   1, ..., n_{\bullet}
   DestorySet(set):
      释放不相交集set所占用的所有空间。
   Find(set, x): 查询元素x所在的集合。
   Union(set, x, y): 合并元素x和元素y所在的集合。
```

## 9.3 不相交集的存储实现

• 思考: Find操作查询元素所在的集合,输入是一个元素,输出是一个集合......

#### • 如何表示一个集合?

- 由于集合是动态变化的,难以实时给集合从1开始按顺序编号
- 技巧: 规定每个集合中X需要有一个"代表"元素 $a \in X$ ,该元素的编号即为集合编号,即
  - Find $(x) = a, \forall x \in X$

• 例:对于划分{{1, 2, 3, 4, 5}, {6, 7}, {8}}, 可规定集合{1, 2, 3, 4, 5}代表元素为1, 则Find(2)=Find(3)=Find(4)=Find(5)=1。

## 9.4 不相交集的基本运算实现

• 不相交集可利用森林的数据结构实现:

- 每个元素x只需维护其父亲结点x.parent。
- 特别地, 规定根结点的父亲结点是其本身, 即x.parent=x。
- 规定森林中的每棵树代表一个不相交集的集合,且其"代表"元素是 其根结点。
- InitSet操作只需定义n棵仅含根结点的树,Find操作只需找到要查询的元素x对应的根结点。而Union操作只需将x和y元素各自对应的根结点合并。

## 9.4 不相交集的基本运算实现

**算法9-1:** 初始化不相交集InitSet(*set*, *n*)

**输入:** 元素的数量*n*, 不相交集*set=*{1, 2, ..., *n*}。

输出:初始化后的集合set。

- 1. for 每个元素 *x*∈ *set* do
- 2.  $| x.parent \leftarrow x$
- 3. end

**算法9-3:** 合并两个元素所在的集合Union(*set,* x, *y*)

**输入**: 不相交集 set 中的两个元素 x和 y。

输出: 合并x和y各自所在集合后的不相交集set。

- 1.  $i \leftarrow \text{Find}(set, x)$
- 2.  $j \leftarrow \text{Find}(set, y)$
- 3. i.parent ← j

**算法9-2:** 查找元素所在的集合Find(set, x)

**输入**:不相交集*set*中待查找的元素*x*。

输出:元素 水所在树的根顶点。

- 1. while  $x \neq x$ .parent do
- 2.  $x \leftarrow x.parent$
- 3. end
- 4. return *x*

## 9.4 不相交集的基本运算实现

- 问题: 在上述实现中, InitSet、Find、Union的操作时间复杂度均可达O(n)
- 考虑森林退化成一条链的情况:  $i.parent = i 1, \forall i = 2,3,...,n$ .
- 这种情况下,每次Find(set, n)均需要O(n)的时间复杂度,而每次Union(set, n-1, n)也需要O(n)的时间复杂度。

朴素的不相交集实现的最坏情况

- 按秩合并策略为每个根结点x引入一个秩x.rank,根结点的秩反映了以该结点为根的子树"大小",考虑利用树的高度作为树的秩:
- 对每个根节点x, 定义其秩x.rank为Ux为根的树的高度减一。
- 特别地, 仅由单个结点构成的树的根结点秩为0。
- 在合并时总是把秩小的树根合并到秩大的树根: 增加树的"宽度"而非"高度"
- 在这种情况下,可保证树的"平衡性":
  - 深度为1的子树至少有21-1个结点。

• 采取按秩合并策略后, InitSet和 Union操作的实现调整为算法9-4、 算法9-5:

**算法9-4:** 初始化采用按秩合并策略的不相交集InitSet(*set*, *n*)

**输入:元素的数**量*n*,不相交集*set=*{1, 2, ..., *n*}。

输出:初始化后的集合set。

- **1. for** 每个元素 *x*∈ *set* **do**
- 2.  $x.parent \leftarrow x$
- 3. | *x.rank* ← 0
- 4. End

**算法9-5:** 利用按秩合并策略合并两个元素所在的集合Union(*set,* x, y)

输入: 不相交集 set 中的两个元素 x和 y。

输出: 合并x和y各自所在集合后的不相交集set。

```
1. i \leftarrow \text{Find}(set, x)
```

- 2.  $j \leftarrow \text{Find}(set, y)$
- 3. if i.rank > j.rank then
- 4. |  $j.parent \leftarrow i$
- 5. else if i.rank < j.rank then
- 6. |  $i.parent \leftarrow j$
- 7. else //i.rank = j.rank
- 8. |  $i.parent \leftarrow j$
- 9.  $\int j.rank \leftarrow j.rank + 1$

**10.end** 

• **引理 9-1**. 在采用按秩合并策略的不相交集算法运行过程中,对于任意子树,若 其根结点秩为r,则该子树中至少有2<sup>r</sup>个结点。

#### 证明.

利用归纳法,对子树根结点的秩r 进行归纳:

- 1. r = 0时子树中仅含一个结点,命题成立。
- 2. 假设命题对所有不超过r 1的 秩成立。考虑根结点root的秩为r > 0 的子树:

由于 r = root. rank > 0,根结点 root的秩必然是与另一棵根为root' 的 树进行Union操作时设置而来。

不失一般性,设该次Union前有:
root.rank = root'.rank = r - 1
否则该次Union前一定存在某次
Union(root, root''), 且
root.rank = root".rank = r - 1;
而Union操作不会令树中的结点数目减少。

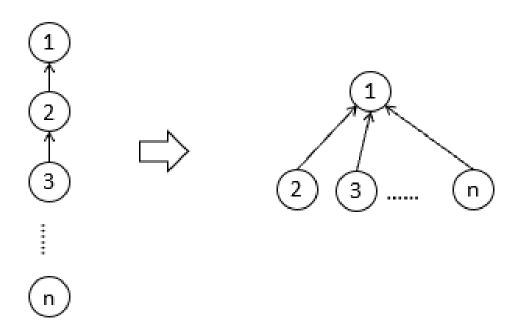
- 3. 由归纳假设,可知此时以root和root为根的子树中都各有至少 $2^{r-1}$ 个结点,故合并后的子树中至少有 $2^r$ 个结点。
  - 4. 由归纳法, 命题对所有r ∈ N成立。

引理 9-1. 在采用按秩合并策略的不相交集算法运行过程中,对于任意子树,若其根结点秩为r,则该子树中至少有2<sup>r</sup>个结点。

• 每次Find、Union操作的时间复杂度取决于查找链的长度,即Find操作 找到的根结点的秩加一。 最坏情况下,全部的n个结点构成一棵树。根据 引理9-1,该树根的秩不超过 $\log n$ 。因此,不相交集每次Find、Union操 作的时间复杂度为 $O(\log n)$ 。

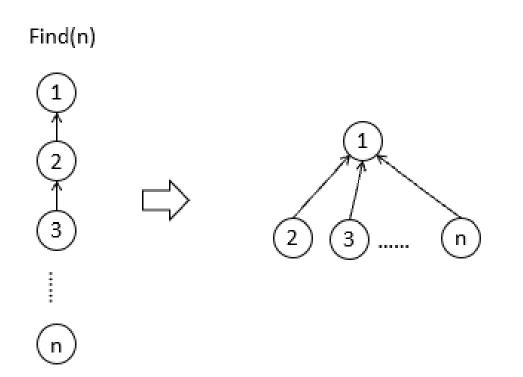
- 假设某次查找时,路径深度过大,导致该次查找的时间成本很高。我们只需调整森林的结构,将查找路径上的所有结点直接连接至根。
- 这样,下次查找这条路径上的结点时只需0(1)时间即可完成。这个技巧称为

路径压缩 (Path Compression) 。 Find(n)



路径压缩

利用路径压缩技巧,不相交集的查找可以重写成为算法9-6。该算法首先递归地查找到根r,之后逐层返回,并将路径上所有结点的父结点均设为r。



**算法9-6:** 以路径压缩策略查找元素所在的集合Find(*set*, *x*)

输入: 不相交集set中待查找的元素x。

输出:元素x所在树的根结点。

- **1.** if  $x \neq x$ .parent then
- 2. |  $x.parent \leftarrow Find(set, x.parent)$
- 3. end
- **4. return** *x.parent*

• 下图演示了同时采用按秩合并和路径压缩策略时,8个元素构成的不相交集的合并过程。

初始时,所有结 点均不相连,结 点的秩均为**0** 



Union(5, 1)时,两结点具有相同的秩,此时将5合并到1,并将结点的秩置为1



Union(6, 5)时,两棵秩为1的树合并成为一棵秩为2的树



树有2^3=8个结点, 在可能出现的秩为3 的树中是结点数目最 少的

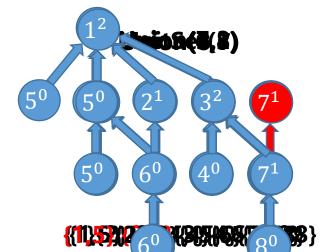


合并操作将两 棵秩为2的树合 并成一棵秩为3 的树



Union(3, 6)时, 首先执行的 Find(6)进行了路 径压缩,将6直 接连接至1

\*此时2成为叶子结点, 但其秩未发生改变。 结点1的秩也仍是2



**Union(3,6)** 

采用了按秩合并和路径压缩的 不相交集运行示例

(\*图中i表示编号为i, 秩为r的顶点)

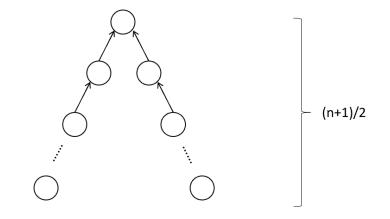
实现不相交集非常简单,但分析其时间复杂度却非常困难。虽然单个操作的时间复杂度较高,最坏可达 O(log n)。然而,由于路径压缩策略的存在,每次访问完一条路径后,下次访问该路径上结点的时间复杂度就会降低,因此算法整体的时间复杂度仍然较低。



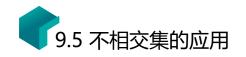
- 使用均摊分析技巧,考虑连续的m个操作的总时间复杂度。
- 可证明,同时使用按秩合并和路径压缩后,n个元素组成的不相交集上进行m次Find/Union操作的时间复杂度为 $O(m\alpha(n))$ ,即每次操作的均摊时间复杂度为 $O(\alpha(n))$ 。其中:
  - $\alpha(n)$ 是增长非常缓慢的函数,对 $n < 10^{80}$ 均有 $\alpha(n) \leq 4$ 。
  - 1080与可观测的宇宙中原子的数目具有相当的数量级。
- 因此, Find/Union操作几乎具有常数时间复杂度。
- 尽管如此,不能称Find/Union具有O(1)的时间复杂度,因为
  - $n \to \infty$ 时, 仍有 $\alpha(n) \to \infty$
- 可证明 $O(\alpha(n))$ 时间复杂度上界是紧的,即不相交集不存在O(1)时间复杂度的算法。



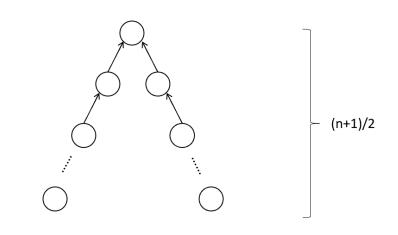
- 在一棵树中,结点u与结点v的公共祖先是所有同时是u和v祖先的结点,而其中深度最大(即离根最远)的结点称为最近公共祖先。
- 给定任意两个结点*山*和 *v*,公共祖先构成一条以根结点为起点的链,而其中最近公共祖先是唯一的。



• 最近公共祖先LCA (Lowest Common Ancestor) 最近公共祖先问题蛮力算法的坏情况 问题考虑m个形如(u, v)的查询,每次需要查询树T中 结点u和v的最近公共祖先。



- LCA问题可用蛮力算法求解:
  - · 首先,从结点u回溯至根,将路径上每个结点 均做标记;
  - 然后,从结点v回溯至根,路径上遇到的第一个有标记的结点即为结点u、v的最近公共祖先。
- 然而,该蛮力算法的时间复杂度较高。
- 如图,若树T中有n个结点,则蛮力算法在最坏情况下每次查询的时间复杂度可达O(n)。



最近公共祖先问题蛮力算法的坏情况



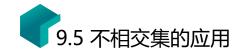
- 求解最近公共祖先问题的离线算法 (Tarjan算法)
- 一次性返回所有m个查询的结果,总时间复杂度仅为 $O(m\alpha(n) + n)$ 。
- Tarjan算法对树进行深度优先遍历,并按遍历的顺序处理询问。
- 若在遍历某结点v时,关于该结点的询问(u,v)的另一端点u已被访问过("闭询问"),则Tarjan算法立即处理该询问
- 否则, 若u尚未被访问("开询问"), 则将此询问留待访问u时完成。



- ·记号:结点r的左子树记为L,右子树记为R。
- · 基本事实: L中的结点u与R中的结点v, 最近公共祖先一定是r。
- 关键:对于一批查询,如何批量地找到每一个查询(u, v)的最近公共祖先r的两个子树?
- 答案: DFS!
- 在DFS中,搜索过程对每个结点r有三次"接触":
  - 第一次: 访问该节点r
  - 第二次: 该节点的左子树L访问完毕后, 第一次回溯到该节点
  - 第三次: 该节点的右子树R访问完毕后, 第二次回溯到该节点



- 设算法已经访问完了根为 r 的子树  $T_1 \in T$  ,并且处理完毕了所有关于  $T_1$  闭询问。
- 需要保留哪些信息以在未来处理T<sub>1</sub>的**开询问**呢?
- 不失一般性,考虑开询问(u,v),其中 $u \in T_1$ 已经被访问,而v尚未被访问。
- 因为v不是子树 $T_1$ 中的结点(否则(u,v)应该是闭询问),所以(u,v)的LCA必然不会是子树 $T_1$ 中的结点,最多只能是子树根r的父亲r.parent。
- 因此,对于后续所有关于 $T_1$ 的开询问,保留子树的结构已无意义,我们可以 将子树中的所有结点合并到结点**r.parent**上。
- 在后续遍历中,**r.parent**代表子树 $T_1$ 中的所有结点,无需再考虑子树 $T_1$ 的具体结构。 该合并操作可以用**不相交集**实现,如算法9-7。



- 在DFS中, 搜索过程对每个结点r有三次接触:
  - 第一次: 访问该节点r
  - 第二次: 该节点的左子树L访问完毕后, 第一次回溯到该节点
  - 第三次: 该节点的右子树R访问完毕后, 第二次回溯到该节点
- 观察访问次序:第二次结束时,可以得知L的所有元素!第二次和第三次之间,访问的结点都在 R中。
- 如果我们在第二次结束时,把所有L中的元素都合并到r中,然后在访问R期间,对于查询( $u \in L, v \in R$ ),都可以知道它们的最近公共祖先为r!
- Tarjan算法如何实现上述思想:
  - 第一次回溯到某个节点时,将它的左子树都合并到该节点上
  - 第二次回溯到某个节点时,将它的右子树也合并到该节点上。
  - 输出LCA(u,v)的时机:若u与v的最近公共祖先是r。1.u已经访问过,2.u所在r的左子树L已经被合并到了r上。3.v的所有子树刚刚合并到v上,此时正好第三次接触到v。4.尚未第三次接触到r,此时正在访问r的右子树R。



**算法9-7:** Tarjan算法求解最近公共祖先 LCA(tree, P, u)

输入: 树 tree, 查询集 $P = \{(u, v)\}$ , 当前结点u。

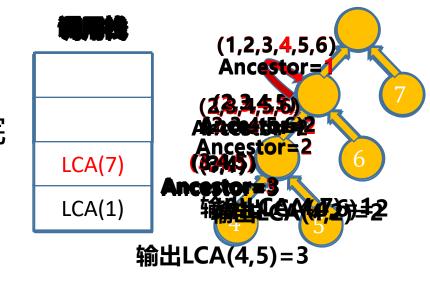
输出: 查询结果LCA。

- *1. set* ← InitSet(*n*) // 初始化不相交集
- *2. ancestor*[Find(*set, u*)]← *u* //初始化
- 3. for *ι*的每个孩子 *ν* do
- 4. | LCA(set, tree, P, v) //深度优先遍历*u*的所有子树
- 5. Union(*set, u, v*) //将子树并到根结点*u*
- 6. | *ancestor*[Find(*set, u*)]← *u* //记录这棵树的根是*u*
- **7.** end
- 8. visited[u]←true
- 9. for  $(u, v) \in P$ 的每个结点v do
- **10**. | **if** *visited*[*v*] **then**
- 11. | | **print** ancestor[Find(set, v)] //输出u和v的LCA
- 12. | **end**
- **13.End**

- 算法的执行过程中,我们维护了两个数组visited和ancestor。
- 其中visited表示结点是否访问完成,用以判断询问是否可完成。
- ancestor表示结点集合(子树)的根。这是因为在采用了按秩合并策略后, Find找到的"根"并不一定是子树实际的根, 因此需要额外记录实际的根。



- 右图是算法运行过程的示意图。
- 本例中有4个询问:分别为LCA(4,5)、LCA(4,6)、LCA(4,2)和LCA(4,7)。
- 右图中依次展示了结点4, 5, 3, 6, 2, 7的孩子访问完成, 即将输出LCA时刻的场景, 对应算法9-7第7行。



算法首先从根结点 开始遍历经过结点 1, 2, 3, 4

断合并遍历路径上的结点,并正确计

在访问结点6时,结点3、4、5的访问均已返回,这些结点均已被合并至结点2。此时询问(4,6)成为闭询问,算法返回{2,3,4,5}这一集合的*ancestor*=2。

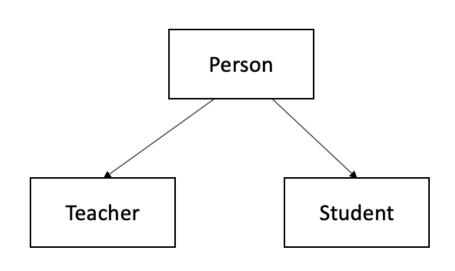
后,将其合并至父亲3。此时结点3、

访问结点5时,有关于该结点的询问(4,5),且4已经访问完成。

\*取决于不相交集的实现,3、4均可能是该集合的代表元素。不失一般性设Find(3)=Find(4)=3,则此时ancestor[3]=3。

◆ \*算法输出(4, 5)的LCA为 ancestor[Find(4)]=ancestor[3]=3

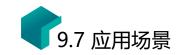


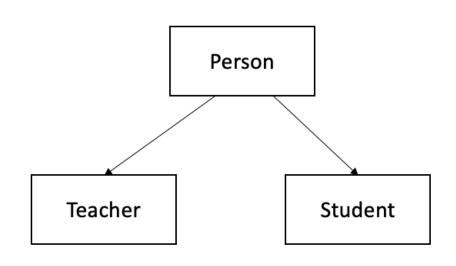


三个类间的继承关系

不相交集在许多计算机科学的真实问题上有应用。如离线最小值查询,求控制流图的支配树,类型推断,实现属性文法 (Property Grammar) 等。近年来,该数据结构在图像处理,数据库和量子计算等领域也有应用。

这里介绍不相交集在面向对象的编程语言中的 应用。





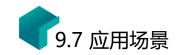
三个类间的继承关系

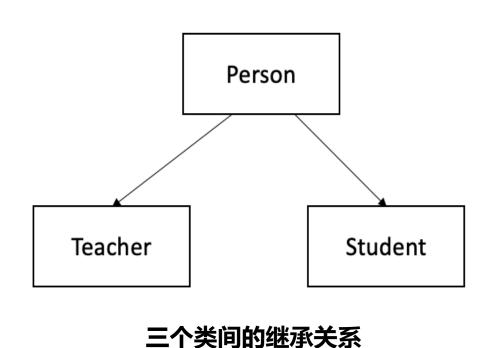
面向对象的编程语言中,变量的类型可以是用户定义的类(class),类之间可以有继承关系。例如说,下列C++代码定义了People、Teacher、Student三个类,其继承关系如图。

```
class Person { ... };
```

class Teacher : public Person { ... };

class Student : public Person { ... };





假如我们定义了如下二元运算Talk:

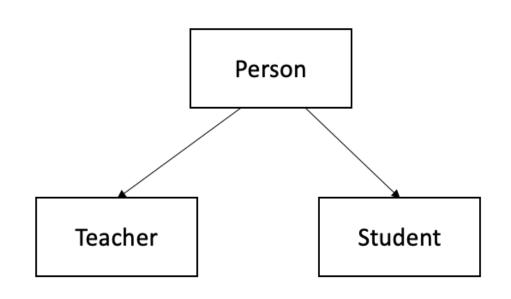
string talk(Person a, Person b);

string talk(Teacher a, Teacher b);

string talk(Student a, Student b);

不同类别之间的Talk函数可以有不同行为。

例如,任意两个Person都可以谈论天气,而只有两个Student才会讨论功课。



三个类间的继承关系

注意,这里我们没有定义两个参数分别是 Teacher和Student的Talk函数。

假如有一个Teacher类型的变量alice和一个Student类型的变量bob,此时若调用talk(alice,bob)会发生什么呢?

实际上,编译器会寻找两个类的最近公共祖先,来调用两个People之间的Talk函数。而最近公共祖先问题又可以用不相交集来解决。

## 谢谢观看